Západočeská univerzita v Plzni Fakulta aplikovaných věd Katedra informatiky a výpočetní techniky

Diplomová práce

Určování nahraditelnosti a kompatibility webových služeb

Plzeň 2020 Zdeněk Valeš

Místo této strany bude zadání práce.

Prohlášení

Prohlašuji, že jsem diplomovou práci vypracoval samostatně a výhradně s použitím citovaných pramenů.

V Plzni dne 27. dubna 2020

Zdeněk Valeš

Abstract

The text of the abstract (in English). It contains the English translation of the thesis title and a short description of the thesis.

Abstrakt

Text abstraktu (česky). Obsahuje krátkou anotaci (cca 10 řádek) v češtině. Budete ji potřebovat i při vyplňování údajů o bakalářské práci ve STAGu. Český i anglický abstrakt by měly být na stejné stránce a měly by si obsahem co možná nejvíce odpovídat (samozřejmě není možný doslovný překlad!).

Obsah

1	$ m \acute{U}vod$				
2	Pri	ncipy v	webových služeb, techniky	8	
	2.1	Webo	vé služby	8	
	2.2	REST		8	
		2.2.1	Technologie použité k realizaci webových služeb	9	
	2.3	Proto	koly	9	
	2.4	Formá	ální popis webových služeb	9	
3	Dat	ové ty	py a porovnávání	11	
		3.0.1	Porovnávání datových typů	11	
4	Zísl	kávání	metadat webových služeb v CRCE	12	
	4.1	CRCE	Ε	12	
		4.1.1	Metadata komponent	13	
		4.1.2	Životní cyklus komponenty v CRCE	14	
	4.2				
		4.2.1	Obecná indexace komponenty	14	
		4.2.2	Indexace komponenty s webovou službou	15	
		4.2.3	Struktura metadat popisující webovou službu	16	
		4.2.4	Indexování REST služeb	16	
		4.2.5	Indexování webových služeb na základě popisu	16	
		4.2.6	Limity indexování	18	
5	Mo	dul pr	o porovnávání webových služeb	19	
	5.1	Repre	zentace rozdílů a kompatibility	19	
	5.2	Algori	itmus porovnání	20	
		5.2.1	Popis algoritmu	20	
		5.2.2	Porovnání datových typů	23	
		5.2.3	Složitost algoritmu	24	
	5.3	Migra	ce webových služeb	25	
		5.3.1	Detekce změn v URL	26	
		5.3.2	Výběr entit k porovnání s příznakem MOV	27	
		5.3.3	Verze REST API v cestě k endpointu	28	
	5.4	Vyhoo	dnocení výsledků	29	
		5.4.1	Dopad na klienta	30	

6	Imp	lemen	tace rozšíření CRCE	32			
	6.1	Porov	návač	32			
	6.2	REST	API	32			
7	Ově	eření fu	ınkčnosti	33			
	7.1	Integr	ační + akceptační testy	33			
		7.1.1	Syntetický server v Jave	33			
		7.1.2	Příklad JSON-WSP z wiki	33			
		7.1.3	FuelEconomy API	34			
		7.1.4	Stag WS	34			
8	Záv	ěr		35			
Li	terat	ura		36			
Se	Seznam zkratek						
Ρì	filoha	a A - V	WSDL webové služby pro komix Dilbert	39			

1 Úvod

 ${\operatorname{-}}$ k čemu je práce dobrá ${\operatorname{-}}$ co text práce obahuje ${\operatorname{-}}$ use casy

2 Principy webových služeb, techniky

V této kapitole jsou definovány webové služby a související pojmy. Jsou zde představeny strojově čitelné způsoby popisu rozhraní služeb a protokoly sloužící ke komunikaci s webovými službami. Tato kapitola také obsahuje popis REST.

2.1 Webové služby

Pojem 'webová služba' má různé významy pro různé lidi, ale dá se najít několik společných bodů [2]:

- Použití HTML, XML a dalších standardů webové architektury jako stavebních kamenů
- Zaměření na podnikové a vnitropodnikové operace
- pro účely této práce je použita následující definice od W3C [7]: "Webová služba je softwarový systém navržený pro podporu mezistrojové komunikace po síti. Webová služba má rozhraní, které je popsáno ve strojově čitelném formátu (konkrétně WSDL). Ostatní systémy interagují s webovými službami předepsaným způsobem za použití zpráv protokolu SOAP, které jsou typicky zprostředkované protokolem HTTP s využitím serializace XML a dalších webových standardů."
 - poskytovatel služby = server
 - konzument služby = klient (typicky nějaká aplikace)

2.2 REST

- mohlo by se hodit: https://www.w3.org/TR/2004/NOTE-ws-arch-20040211/#relwwwrest
- popisuje vztah REST a WWW REST: založeno na manipulaci s XML reprezentací webových resources skrze stateless operace
- popis architektonického stylu REST: https://www.ics.uci.edu/fielding/pubs/dissertation/re
 popis elementů: data, konektory, komponenty popis view(na modelování)
 - RFC na HTTP: https://tools.ietf.org/html/rfc7231#section-4
- odkaz konkrétně na request methods, mohlo by se hodit, protože ty jsou indexovány, tak alespoň na citaci



Obrázek 2.1: Technologie zahrnuté ve webových službách

- verzování API: https://www.xmatters.com/blog/devops/blog-four-rest-api-versioning-strategies/
- další verzování: https://www.troyhunt.com/your-api-versioning-is-wrong-which-is/

2.2.1 Technologie použité k realizaci webových služeb

- zmínit: RPC, SOAP

2.3 Protokoly

- relevantní protokoly: RPC, SOAP, HTTP
 - HTTP (na REST a WS obecně)
 - protokol aplikační vrstvy SOAP (web service)
 - XML pro popis datového modelu
 - specifikace SOAP: https://www.w3.org/TR/soap12-part1/#intro

2.4 Formální popis webových služeb

- existují různé, strojově čitelné, formáty pro popis API
 - WSDL 1.1, 2.0, WADL (REST), JSON-WSP

- Swagger, Raml, OpenApi
- v případě REST bohužel není nic formálně nutné (oproti třeba SOAP), takže specifikace API nemusí být kompatibilní, nemusí být úplné, nebo můžou být ad-hoc (např. slovní popis ve Word dokumentu) a tím pádem nemusí existovat univerzální způsob strojového čtení těchto specifikací
 - v mé práci se věnuji především formátům WSDL, WADL a JSON-WSP

3 Datové typy a porovnávání

- přednášky z FJP - jak jazyky řeší datové typy - rekurzivní vs. nerekurzivní - primitivní typy (v xsd) - built-in typy (v Jave) - tady budu citovat [1] - subtyping: A <: B <=> A může být použito v kdekoliv kde je očekáváno B - kontravariance: F'(A) <: F(B) <=> B <: A

3.0.1 Porovnávání datových typů

- jak to funguje - problémy při porovnání - subtyping vs. matching $\left([1]\right)$

4 Získávání metadat webových služeb v CRCE

Cílem této práce je vytvořit rozšíření pro úložiště CRCE¹, které bude schopno vyhodnocovat vzájemnou kompatibilitu indexovaných webových služeb. Tato kapitola představuje samotné úložiště, formát metadat a obecný způsob jejich získání. Na konci kapitoly je popsán princip fungování konkrétních rozšíření, která indexují webové služby (tzv. indexery).

4.1 CRCE

CRCE je komponentové úložiště dlouhodobě vyvíjené a spravované výzkumnou skupinou ReliSA na Katedře Informatiky ZČU, jehož primárním účelem je indexace a následná kontrola vzájemné kompatibility komponent. Úložiště je postaveno na modulární architektuře (viz obrázek 4.1) a je tedy možné přidat rozšíření pro indexaci a zpracování vlastních dat.



Obrázek 4.1: Architektura CRCE

¹Component Repository supporting Compatibility Evaluation

4.1.1 Metadata komponent

Data, která vzniknou indexací komponenty a případným dalším zpracováním (např. porovnáním) jsou uložena do souboru metadat a představují klíčový element systému CRCE. Návrh struktury těchto metadat, který je naznačen na obrázku 4.2, vychází z konceptu OBR² jehož základními entitami jsou mimo jiné *Resource*, requirements a capabilities[3].

Entita Resource reprezentuje komponentu uloženou v CRCE, requirements a capabilities jsou množiny vlastností, popisující co komponenta ke své správné funkci vyžaduje, respektive co naopak poskytuje. Model také umožňuje přidání key-value atributů k jednotlivým vlastnostem a jejich detailům.



Obrázek 4.2: Reprezentace metadat v CRCE

V mé práci jsem pracoval především s poskytovanými vlastnostmi (množina capabilities) a proto zde popíši hlavně jejich strukturu. Každá konkrétní vlastnost je reprezentována elementem Capability a od ostatních je odlišena identifikátorem namespace. Detaily konkrétní vlastnosti jsou popsány elementy Property a Attribute, kde Property reprezentuje logický celek několika atributů. Například parametr endpointu REST služby shlukuje atributy popisující jeho jméno, datový typ atp. Attribute pak představuje pár klíčhodnota, který nese konkrétní informace jako např. jméno endpointu, nebo datový typ parametru.

Z obrázku 4.2 je vidět rekurzivní povaha elementu *Capability*, čehož je využito ke skládání jednodušších vlastností do složitějších celků. Vznikne tím stromová struktura, která je vhodná k modelování hierarchických dat mezi něž patří například popisy webových služeb. V případě takto komplexních vlastností je ke komponentně (*Resource*) přiřazena pouze jedna, tzv. kořenová, *Capability*, která reprezentuje celou vlastnost.

²OSGi bundle repository

4.1.2 Životní cyklus komponenty v CRCE

Úložiště bylo původně navrženo pro ukládání OSGi komponent, nicméně indexovat lze jakoukoliv komponentu. Komponenta je v CRCE popsána již zmíněnými metadaty a prochází vlastním životním cyklem naznačeným na obrázku 4.3.



Obrázek 4.3: Životní cyklus komponenty v CRCE

Životní cyklus má dvě hlavní fáze, jimiž jsou *Buffer* a *Store*. Komponenta po nahrání do úložiště nejprve prochází fází *Buffer*, v níž dojde k indexaci obsahu, kontrole vnitřní konzistence a kompatibility komponenty. Pokud touto fází projde bez chyb, je komponenta nahrána do trvalého úložiště (operace *commit*) a přechází do fáze *Store*.

V obou fázích jsou nad komponentou prováděny operace z nichž analyze je nejvíce relevantní mé práci, protože právě během této operace dochází ke sběru metadat (fáze Buffer) a dalším výpočtům nad nimi (fáze Store). Modul s rozšířením, který je předmětem mé práce bude zařazen mezi výpočty prováděné nad metadaty během analyze, kde bude vyhodnocovat vzájemnou kompatibilitu webových služeb. Způsoby sběru těchto metadat, ke kterým dochází ve fázi Store, jsou popsány v následující sekci.

4.2 Indexování webových služeb

V této podkapitole je krátce popsán obecný způsob indexace komponent v CRCE. Následně je podrobněji rozebráno indexování webových služeb konkrétními moduly a reprezentace popisu API metadaty v CRCE. Na závěr jsou také uvedeny limity indexování.

4.2.1 Obecná indexace komponenty

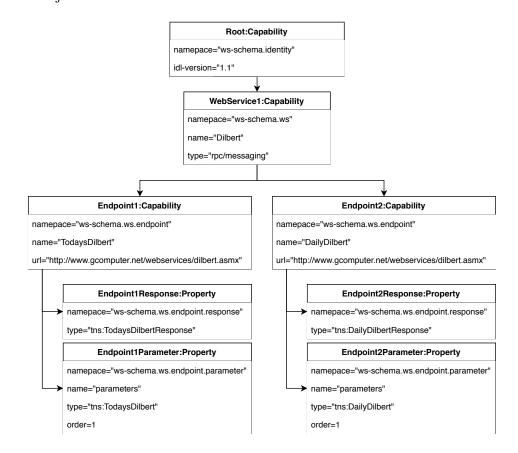
Indexace komponenty a související sběr metadat je proveden ve fázi *Buffer* k tomu určenými moduly. Ty jsou vzájemně nezávislé a obecně platí, že každý nich je zaměřen na sběr nějaké logicky ucelené části dat jako například informace o OSGi bundlu, maven koordináty, nebo popis webových služeb.

Vlastní data komponenty zůstávají během tohoto procesu nezměněná což v kombinaci s řetězením indexerů zaručuje mimo snadnou rozšiřitelnost také transparentní přístup ke komponentě každému z nich.

4.2.2 Indexace komponenty s webovou službou

Soubor obsahující implementaci, nebo popis API je v CRCE vnímán jako komponenta a prochází tedy zmíněným životním cyklem včetně výše popsané indexace. Pro popis webových služeb existuje mnoho standardních i nestandardních způsobů, jak již bylo zmíněno v kapitole 2. Z tohoto důvodu je není možné všechny analyzovat jedním indexerem a je nutné zaměřit se pouze na část z nich.

V současné době tedy existují dva moduly podporující několik popisných formátů a implementací. Konkrétně se jedná o modul pro indexaci webových služeb založených na architektonickém stylu REST[5] a o modul pro indexaci webových služeb s popisem ve formátu WSDL, WADL, nebo Json-WSP [6]. Oba dva vznikly v rámci diplomových prací a jsou stručně popsány v následujících sekcích.



Obrázek 4.4: Příklad indexované SOAP webové služby pro komix Dilbert

4.2.3 Struktura metadat popisující webovou službu

Jak již bylo zmíněno v části 4.1.1, hierarchickou strukturu popisu API lze vhodně vyjádřit metadaty CRCE. Během indexování komponenty reprezentující API jsou shromážděny různé typy popisných vlastností. Jedním z těchto typů je i samotný popis webové služby, který je reprezentován stromem metadat a ke komponentě je přiřazen skrze kořenovou *Capability*.

I když jsou různé druhy API indexovány rozdílnými moduly, výsledná metadata mají podobnou strukturu. Příklad metadat API je zobrazen na objektovém diagramu 4.4, jedná se o webovou službu, která vrací strip komixu Dilbert pro dnešní den.

Z uvedeného obrázku je vidět, že klíčové elementy API jako web service, nebo endpoint jsou reprezentovány objektem *Capability*. Detaily těchto elementů jsou popsány objekty *Property*. Jedná se zejména o parametry endpointů, těla requestů a response. Objekt *Attribute* pak představuje konkrétní hodnoty, jež jsou na obrázku naznačeny jen jako páry "klíč=hodnota". *Attribute* nemusí být vázaný jen na *Property* a lze jej použít i pro popis *Capability*, jak je tomu např. u objektu *WebService1*.

4.2.4 Indexování REST služeb

Modul pro indexování REST API vznikl v rámci diplomové práce Bc. Gabriely Hessové. Princip sběru dat je založen na binární analýze java archivů (JAR) obsahujících implementaci REST služeb pomocí frameworků splňujících specifikaci JAX-RS a frameworku Spring Web MVC. Modul byl testován na frameworcích Jersey verze 2.26, RESTEasy verze 3.0.16 a Spring Boot verze 1.5.9 [5].

Z implementace REST služby modul rekonstruuje kolekci endpointů s jejich parametry, tělem requestu, response a případnými parametry response. Každý endpoint je reprezentován entitou *Capability*, všechny další jeho vlastnosti pak entitami *Property*. Výčet všech indexovaných elementů rozhraní je uveden v tabulce 4.1.

4.2.5 Indexování webových služeb na základě popisu

Modul pro indexování webových služeb vznikl v rámci práce Bc. Davida Pejřimovského. Oproti předchozímu modulu pro indexaci REST služeb nepracuje tento s její implementací, ale s popisným souborem služby, tak jak bylo uvedeno v kapitole 2. Podporované formáty popisu služeb jsou WSDL (verze 1.1 i 2.0) pro SOAP webové služby, WADL a Json-WSP pro REST služby[6].

Element API	Entita v metadatech	Vstaženo k
Endpoint	Capability	-
Request body	Property	Endpoint
Request parameter	Property	Request
Response	Property Endpoint	Endpoint
Response parameter	Property	Response

Tabulka 4.1: Seznam indexovaných elementů REST služby a jejich reprezentací v metadatech

Struktura dat vytvořených pro REST služby (tedy z popisu WADL, nebo Json-WSP) je podobná struktuře dat vytvořenou předchozím indexerem. Endpoint je tedy reprezentován entitou *Capability*, jeho parametry entitami *Property*. Z popisu Json-WSP je ještě vytvořena reprezentace response pro daný endpoint (entita *Property*). Z popisu WADL se žádné další vlastnosti endpointů nezískávají.

Z WSDL popisu je vytvořena reprezentace služeb, jež jsou popsány xml elementy <wsdl:service> a jejich vnořených endpointů. Endpoint je ve WSDL popsán elementem <wsdl:port> a má definované operace (elementy <wsdl:operation>), nicméně modul tyto nevnořuje a vytváří zjednodušenou reprezentaci. Model endpointu tedy obsahuje metadata získaná z elementů <wsdl:operation> a url definovanou v elementu <wsdl:port>. Služby i endpointy jsou v metadatech reprezentovány entitami Capability. Oproti REST službám, které mají jednu úroveň vnoření Capability, zde vznikají úrovně dvě. Výčet elementů API a jejich reprezentace v metadatech je uveden v tabulce 4.2.

Element API	Entita v metadatech	Vstaženo k
Service	Capability	-
Endpoint	Capability	Service
Endpoint parameter	Property	Endpoint
Response	Property	Endpoint
Response parameter	Property	Endpoint

Tabulka 4.2: Seznam indexovaných elementů webové služby a jejich reprezentací v metadatech

Logika parsování WSDL souborů (verze 1.1. i 2.0) obsahovala chybu ve čtení adresy endpointu. Ta byla očekávána v atributu action elementu <wsdl:operation>, který ale není uveden ve specifikaci WSDL 1.1 [8] ani WSDL 2.0 [9]. Tuto chybu jsem v rámci mé práce opravil.

4.2.6 Limity indexování

Současný proces indexování webových služeb naráží na dva známé problémy týkající se datových typů. Jedná se o indexování rekurzivních datových typů a absenci samotných definic typů.

První problém se týká zejména indexování webových služeb podle popisných souborů, protože ty definice typů obsahují. Způsoby rozvoje a ukládání datových typů jsou popsány v [1], nicméně logika zatím není implementována. Druhý problém se týká binární analýzy REST služeb, protože archiv s implementací služby nemusí nutně obsahovat definice tříd. Ty mohou být například v jiném artefaktu, na který se archiv pouze odkazuje skrze závislost.

Z těchto důvodů je do metadat uložen pouze název datového typu což snižuje možnosti porovnávání služeb.

5 Modul pro porovnávání webových služeb

V této kapitole je detailně popsána funkce porovnávacího algoritmu společně s daty, nad kterými je možné porovnávač použít. Zároveň je zde popsán způsob vyhodnocení výsledků porovnání a formát uložení takto získaných dat.

5.1 Reprezentace rozdílů a kompatibility

Webové služby jsou popsány komplexní strukturou metadat, která byla uvedena v předchozí kapitole. Rozdíl mezi těmito strukturami lze vyjádřit pouhou pravdivostní hodnotou (stejné, nebo nestejné), nicméně takový přístup skrývá před klientem většinu informací, na základě kterých by se mohl rozhodnout o dalším postupu a tím značně snižuje použitelnost aplikace. Mimo to, samotná skutečnost, že metadata webových služeb se neshodují nemusí nutně z pohledu klienta znamenat nekompatibilitu. Z těchto důvodů je k reprezentaci rozdílů mezi službami třeba použít vhodnější metodu.

Článek [4] zabývající se možnostmi evaluace kompatibility komponent na základě relace subtypingu, nahlíží na komponentu skrze její rozhraní jako na datový typ a popisuje odlišnosti v různých úrovních kontraktu (metoda, parametr, ...). Na základě těchto odlišností (a relace subtypingu) je pak určena míra kompatibility dvou komponent. Protože je webová služba v CRCE reprezentována komponentou a na její rozhraní se dá také nahlížet jako na kontrakt datového typu, je tento přístup vhodný k reprezentaci rozdílů mezi webovými. Oproti pouhé pravdivostní hodnotě je navíc klientovi poskytnuta detailní informace o konkrétních rozdílech mezi službami. Z těchto důvodů jsem se rozhodl použít výše zmíněný způsob reprezentace rozdílů v mé práci.

Datové struktury použité pro reprezentaci rozdílů dvou entit a jejich vzájemné kompatibility navržené v rámci citovaného článku se nazývají Diff a Compatiblity. Diff je definován jako rekurzivní typ, který uchovává jak konkrétní informace o rozdílu skrze podřazené Diff tak i úroveň odlišnosti zvanou Difference. Tyto úrovně jsou popsány tabulkou 5.1 a v citovaném článku tvoří obor hodnot funkce $diff(a,b): Type \times Type \rightarrow Difference$. Třída Compatibility uchovává informace o kompatibilitě dvou komponent (reprezentovány entitami Resource) společně s detaily jejich rozdílů, jež jsou

reprezentovány stromem Diff.

Název úrovně	Zkratka	Váha	Popis
None	NON	1	a = b
Insertion	INS	2	a není definováno, ale b ano
Deletion	DEL	2	a je definováno, ale b ne
Specialization	SPE	3	b je subtyp a $(b <: a)$
Generalization	GEN	3	a je subtyp b $(a <: b)$
Mutation	MUT	4	kombinace INS/SPE a DEL/GEN
Unknown	UNK	5	a nelze porovnat s b

Tabulka 5.1: Popis úrovní rozdílů

Způsob vyhodnocení rozdílů dvou webových služeb společně s významem jednotlivých úrovní *Difference* a jejich vah pro klienta je popsán na konci této kapitoly. Pro přehlednost jsou jednotlivé úrovně rozdílů v průběhu kapitoly nazývané jejich zkratkami.

5.2 Algoritmus porovnání

Porovnávací algoritmus pracuje s metadaty popsanými v části 4.1.1. Jedná se o stromovou strukturou, jejíž uzly tvoří instance tříd *Capability, Property* a *Attribute*, kde objekty *Attributes* jsou listy této struktury . Soubor metadat může obsahovat další vlastnosti komponenty, která představuje webovou službu, ta však zůstanou nedotčena, protože algoritmus pracuje pouze s daty, která byla vytvořena indexery popsanými v části 4.2.

Moduly pro indexování webových služeb popsané v předchozí kapitole používají dvě různé množiny namespace identifikátorů po pojmenování entit Capability, Property a Attribute. Do budoucna je zároveň plánované rozšíření těchto modulů o funkcionalitu pro indexování datových typů a datová struktura metadat je tedy předmětem změny. Z těchto důvodů je algoritmus schopen porovnat pouze metadata vytvořená stejným indexerem a používající stejné namespace identifikátory. Není tedy možné vzájemně porovnat například metadata REST služby získaná binární analýzou JAR s metadaty získanými čtením JSON-WSP dokumentu i když by se mohlo jednat o jednu službu.

5.2.1 Popis algoritmu

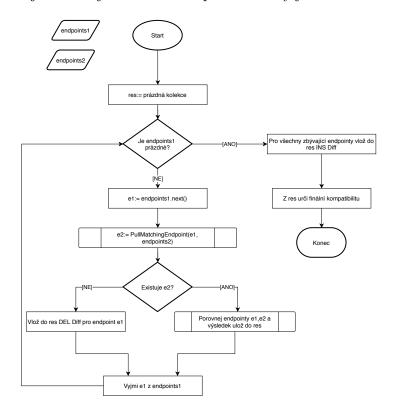
Vstupem algoritmu jsou reprezentace obou webových služeb v podobě objektů *Resource*, z kterých jsou následně k porovnání vybrány kolekce end-

pointů, případě kolekce *service* obsahující endpointy. Výstupem algoritmu je objekt *Compatibility*, jež obsahuje detailní popis rozdílů mezi webovými službami ve formátu popsaném v sekci 5.1.

Před porovnáváním datových struktur je zkontrolována jejich kompatibilita. Ta je dána následujícími vlastnostmi:

- typ popisu: z čeho byla metadata získána (implementace, formát popisného souboru),
- typ komunikace: jakým způsobem lze službu volat,
- *identity capability*: obsahuje informace o identitě komponenty v CRCE.

Pokud kontrola proběhne úspěšně, je spuštěn samotný algoritmus jehož průběh je naznačen na vývojovém diagramu 5.1. V případě porovnání SOAP webových služeb je tento postup obalen ještě porovnáním *services*, které WSDL definuje a které jsou v CRCE reprezentovány jako kolekce endpointů.



Obrázek 5.1: Vývojový diagram porovnávacího algoritmu

Mezivýsledky porovnání jsou ukládány v datové struktuře *Diff*, která je detailně popsaná v sekci 5.1. Algoritmus postupuje po stromu metadat od kořene směrem k listům, ve kterých dojde k porovnání konkrétních hodnot

a vyhodnocení rozdílů mezi nimi. Rozdíl mezi dvěma ne-koncovými uzly je vyhodnocen až po porovnání všech jejich potomků (nezávisle na pořadí). Algoritmus tedy postupuje zpět ke kořeni stromu, který na konci algoritmu obsahuje finální údaj o rozdílu obou služeb. Jednotlivé fáze porovnání jsou popsány v následujících odstavcích.

Výběr entit vhodných k porovnání

Tento odstavec se týká endpointů a service, protože tyto nejsou na pořadí závislé (na rozdíl např. od parametrů operace) a jejich pořadí v metadatech nelze ani předpokládat. Proto je nutné před samotným porovnáním nejprve vybrat dvojici entit k tomu vhodnou. Endpoint e1 (service s1) z první webové služby je vybrán sekvenčně, jak je naznačeno na diagramu 5.1. Druhý endpoint e2 (s2) je pak vybrán na základě určité shody s metadaty endpointu e1, respektive service s2. V přípdě endpointů se konkrétně jedná o počet povinných parametrů, jméno a URL na které je daný endpoint dostupný. URL nemusí být shodné úplně. Pokud tak nastane, je nastavena vlajka MOV, která je detailně popsána v sekci 5.3.

O porovnatelnosti a rozdílu dvou *services* je rozhodnuto na základě úplné shody jejich jmen a typu (současně je používán pouze typ "rpc/messaging").

Porovnání dvou endpointů

Po výběru vhodné dvojice endpointů dojde k jejich porovnání. Postupně se porovnají (pokud jsou pro daný typ webové služby definovány) parametry, response a těla request. Způsob porovnání parametrů a response je rozveden v následujících odstavcích. Metadata těla request jsou dostupná pouze v případě REST služeb indexovaných na základě implementace a detail jejich porovnání je znázorněn v tabulce 5.2. U atributu *isOptional* může dojít ke změně *GEN* pokud se povinný atribut stane nepovinným. V opačném případě se jedná o změnu *SPE*.

Název atributu	Možné výsledky
isArray	NON, UNK
is Optional	NON, GEN, SPE
dataType	NON, GEN, SPE, UNK

Tabulka 5.2: Porovnání atributů těl requestů endpointů

Porovnání response dvou endpointů

Element response je definovaný ve všech případech kromě služeb popsaných WADL. V případě REST služeb indexovaných na základě implementace jsou navíc definovány i parametry response a může také existovat více elementů response pro jeden endpoint. Ty jsou navzájem odlišeny atributem id, jehož hodnotu vytváří indexer. Detail porovnání response (včetně parametrů) REST služeb je uveden v tabulce 5.3, tabulka 5.4 pak obsahuje detail porovnání response ostatních služeb.

Název atributu	Možné výsledky
isArray	NON, UNK
dataType	NON, GEN, SPE, UNK
status	NON, UNK
parameterName	NON, UNK
parameter Category	NON, UNK
parameterIsArray	NON, UNK
$\overline{parameter Data Type}$	NON, GEN, SPE, UNK

Tabulka 5.3: Porovnání atributů response a parametrů response endpointů REST služby

Název atributu	Možné výsledky	
isArray (pouze JSON-WSP)	NON, UNK	
dataType	NON, GEN, SPE, UNK	

Tabulka 5.4: Porovnání atributů response ostatních služeb

Porovnání parametrů endpointů

Množiny porovnávaných atributů parametrů se navzájem liší podle typu metadat služby (viz kapitola 4.2). Kompletní přehled je uveden v tabulce 5.5. Parametry endpointů vhodné k porovnání jsou vybrány na základě jejich jména (atribut *name*). Po výběru dojde k porovnání zbylých atributů a rozdíl mezi parametry je vyhodnocen na základě rozdílů mezi jejich atributy.

5.2.2 Porovnání datových typů

V současnosti jsou největším omezením porovnávacího algoritmu datové typy. Jak již bylo zmíněno v kapitole 4.2, jméno datového typu je jedinou

Název atributu	Typ metadat služby	Možné výsledky
name	všechny	NON, UNK
dataType	všechny	NON, GEN, SPE, UNK
order	všechny krom WADL	NON, UNK
is Optional	všechny krom WSDL	NON, GEN, SPE, UNK
isArray	REST a JSON-WSP	NON, UNK
category	REST	NON, UNK

Tabulka 5.5: Porovnání parametrů endpointů

dostupnou informací a tedy také jediným kritériem, podle kterého je lze porovnávat. To je dostatečné v případě vestavěných typů jako například třídy z balíku java.lang, nebo typy definované v xsd.

Nad těmito lze provádět plnohodnotné porovnání včetně kontroly generalizace (změny GEN, SPE). U vestavěných typů Javy je generalizace určena na základě dědičnosti a lze například určit, že datový typ s názvem java.lang.Number je generalizací typu s názvem java.lang.Long, protože třída Number je rodičem třídy Long. Obdobně je tomu i u vestavěných typů definovaných v xsd, kde je generalizace a <: b definována v případě, že typ b je dost velký na pojmutí typu a. Například typ xsd:long dokáže reprezentovat číslo typu xsd:int a proto platí, že xsd:int <: xsd:long.

Porovnání vestavěných typů je založeno na podmínce správně zaindexovaného jména datového typu. V případě analýzy byte kódu je tato podmínka splněna, nicméně u metadat získaných čtením popisných XML souborů tomu tak vždy nemusí být. Problém spočívá v předponě datového typu, která je součástí jeho jména a porovnávací algoritmus očekává její určitou hodnotu (konkrétně xs). Hodnota předpony je však určena definicí namespace v XML popisu a ta se může od očekávané lišit. Tato definice není indexerem ukládána a není proto možné ji během porovnání přesně určit.

Pro uživatelsky definované typy je porovnání omezeno pouze na úplnou shodu, protože na základě pouhého jména datového typu nejde s jistotou usoudit nic dalšího. Změny pro jednotlivé rozdíly mezi datovými typy jsou uvedeny v tabulce 5.6.

5.2.3 Složitost algoritmu

Algoritmus v zásadě porovnává kolekce endpointů webových služeb a jejich počet je tedy hlavní parametr, od kterého se odvíjí výpočetní složitost. V případě SOAP webových služeb jsou operace definované v rámci service a je tedy třeba brát v úvahu i jejich počet. Nárůst složitosti je ovlivněn výběrem

Vztah typů	Výsledek
A = B	NON
A <: B	GEN
B <: A	SPE
A! = B	UNK

Tabulka 5.6: Rozdíly mezi datovými typy A a B

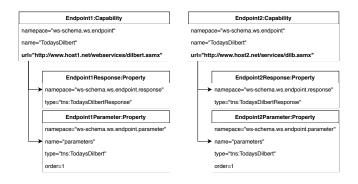
vhodných párů entit k porovnání, konkrétní hodnoty pro nejlepší a nejhorší případy jsou uvedeny v tabulce 5.7.

Typ služby	Složitost	
REST, WADL, JSON-WSP	$\Omega(n),O(n^2)$ kde n je počet endpointů	
WSDL	$\Omega(mn), O((mn)^2)$ kde m je počet service a n je počet endpointů	

Tabulka 5.7: Složitost algoritmu

5.3 Migrace webových služeb

V popisu porovnání metadat endpointů bylo zmíněno použití URL endpointu jako identifikátoru. Tento přístup naráží na problém, pokud poskytovatel webovou službu přesune, nebo provede změny v cestě k danému endpointu. Na obrázku 5.2 je uveden příklad dvou shodných endpointů, jež se liší pouze v URL. Aplikujeme-li výše popsaný algoritmus na tato data, skončí negativním výsledkem i přes to, že endpointy mají totožné rozhraní a klient by k nim mohl bez obtíží přistoupit.



Obrázek 5.2: Příklad shodných endpointů s rozdílnou URL

Podobným příkladem je i verze API v cestě k endpointu. Klient může mít

požadavek na zjištění kompatibility API dvou různých verzí, ale algoritmus vrátí rozdíl MUT, protože endpointy z prvního API vyhodnotí jako chybějící v API druhém a naopak, právě kvůli rozdílným cestám. Tím vznikne kombinace rozdílů DEL a INS, která vede na MUT. Takové chování není žádané a je potřeba těmto problémům předcházet, proto je nutné případné změny v URL detekovat a brát je při porovnávání v potaz.

Jako řešení popsaného problému byl zaveden příznak "MOV", který je ortogonální k úrovni změny (*Difference*) popsané v předchozích sekcích a je součástí objektu *Diff.* Díky ortogonalitě je možné stále určit méně nebezpečné rozdíly jako generalizaci v příznaku parametru (SPE) a zároveň předat klientovi informaci o změně v URL.

Příznak MOV má smysl brát v úvahu jen u případů porovnání jejichž úroveň změny je v podmnožině NON, GEN, SPE, která je v rámci této sekce označována jako bezpečná. Všechny ostatní úrovně představují v kontextu migrace příliš velkou změnu. Je tedy například nesmyslné nastavit příznak MOV u rozdílu dvou endpointů s úrovní změny DEL, protože samotná úroveň změny říká, že endpoint nebyl v druhé webové službě nalezen a proto nelze ani určit zda byl přemístěn.

5.3.1 Detekce změn v URL

Součástí URL endpointu je také jeho název, změny v URL se tedy dají detekovat na třech místech. Prvním z nich je doména (včetně protokolu), druhým je cesta k endpointu a třetím jeho jméno. URL všech endpointů obou webových služeb jsou podle těchto částí rozděleny, čímž vznikne 6 množin (2 pro každou část URL). Pokud platí, že $url_{i,1} \subseteq url_{i,2}$ kde url_i , j je i-tá část url j-té webové služby, je daná část URL považována za nezměněnou. Příklad rozdělení URL dvou webových služeb vycházející z obrázku 5.2 je uveden v tabulce 5.8. V tomto příkladu by byla detekována změna v částech URL "Doména" a "Cesta".

$url_{i,j}$	Služba 1 (j=1)	Služba 2 (j=2)
Doména (i=1)	$\{http://host1.net\}$	$\{http://host2.net\}$
Cesta (i=2)	$\{webservices/dilbert.asmx\}$	$\{services/dilb.asmx\}$
Operace (i=3)	$\{TodaysDilbert\}$	$\{TodaysDilbert\}$

Tabulka 5.8: Příklad rozdělění URL na části podle obrázku 5.2

Výsledek detekce změn v URL nese tři příznaky, kde každý z nich určuje, zda byla v dané části URL detekována změna. Vzhledem k tomu, že algoritmus detekce pracuje pouze s URL a jmény endpointů, může dojde k

pozitivnímu výsledku i v případě, že jsou porovnávány dvě odlišné webové služby. Aby se redukoval počet false-positives, je potřeba určit, které kombinace příznaků změny mohou vést na MOV a které představují příliš velké odchýlení. Tyto kombinace jsou uvedeny v tabulce 5.3.1, kde proměnné $h,\,p,\,n$ označují změnu v doméně, cestě a jménu endpointu. Hodnota true značí změnu.

Kombinace	MOV	Zdůvodnění
$!h \wedge !p \wedge !n$	ne	Nebyla detekována žádná změna.
$h \land !p \land !n$	ano	Změna v doméně, může se jednat o migraci webové služby.
$!h \wedge p \wedge !n$	ano	Změna v cestě k endpointům, může se jednat o restrukturalizaci služby.
$h \wedge p \wedge !n$	ano	Může se jednat o kombinaci obou předchozích.
všechny ostatní	ne	Změna je příliš velká.

Z tabulky je vidět, že změna ve jménech endpointů vždy vede na záporný výsledek. Důvodem je fakt, že jméno endpointu je druhé kritérium pro výběr vhodného páru endpointů (prvním je URL) a bez něj by algoritmus zdegradoval na porovnání "každý s každým"což by značně snížilo efektivitu.

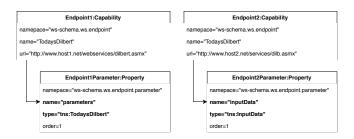
5.3.2 Výběr entit k porovnání s příznakem MOV

Protože jedním z kritérií pro výběr vhodného páru endpointů je i URL, je potřeba upravit logiku výběru tak, aby byly brány v potaz výsledky detekce popsané v předchozí sekci. Při porovnávání URL dvou endpointů je podle kombinace změn daná část URL ignorována a pracuje se pouze s nezměněnou částí u které je vyžadována striktní rovnost.

Tento způsob může vést na případy, kdy je dvojce endpointů vyhodnocena jako potencionálně vhodná k porovnání (s nastaveným příznakem MOV), nicméně porovnání skončí negativním výsledkem, například *UNK*. Pouhá akceptace takového výsledku a pokračování algoritmu by mohlo zapříčinit negativní vyhodnocení kompatibility webových služeb v případech, kdy skutečný rozdíl není tak silný.

Příklad na obrázku 5.3 tento problém znázorňuje. Oba endpointy mají stejný název a proto by byly vybrány jako vhodné k porovnání s nastavenými MOV příznaky h=t, p=t, o=f. Hlubší porovnání by však skončilo výsledkem UNK, protože se neshodují jména a datové typy jejich parametrů.

Algoritmus by tedy služby vyhodnotil jako nekompatibilní i přes to, že by mohla existovat kombinace kompatibilních endpointů.



Obrázek 5.3: Příklad dvou rozdílných endpointů, pro které by byl nastaven příznak MOV

Algoritmus 'pick best'

Řešením zmíněného problému je algoritmus 'pick best', který postupně porovnává dvojice endpointů (k tomu předem vybrané) a jako výsledek vrátí dvojici s nejlepším rozdílem. Vstupem algoritmu je tedy endpoint z první webové služby e1 a množina endpointů druhé webové služby endpoints2.

Algoritmus postupně vybírá elementy e2 z endpoints2 a pokud je pár e1, e2 vyhodnocen jako porovnatelný, dojde k detailnímu porovnání. V případě výsledku spadajícího do bezpečné množiny (NON, GEN, SPE) je pár e1, e2 vrácen a porovnání pro endpoint e1 je ukončeno. V opačném případě je negativní výsledek uložen a z množiny endpoints2 jsou vybírány další porovnatelné endpointy dokud algoritmus nedojde ke dvojici, jejíž rozdíl spadá do bezpečné množiny, nebo dokud není endpoints2 vyčerpána. Pokud je množina endpoint2 vyprázdněna, znamená to (alespoň částečnou) nekompatibilitu obou webových služeb a je vrácen první porovnávaný pár e1, e2.

5.3.3 Verze REST API v cestě k endpointu

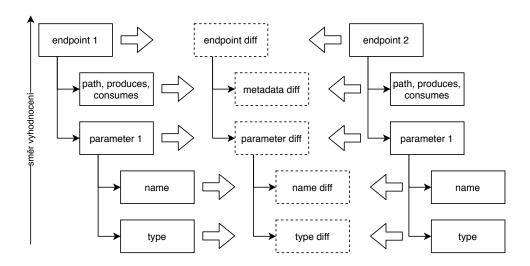
Jednou ze speciálních změn detekovatelných v cestě k endpointu je verze API. Jedná se o běžnou praktiku [10] a k jejímu zpracování lze použít jednodušší přístup, než byl dosud popsán. Část cesty, která obsahuje verzi lze jednoduše vypustit a porovnat URL bez verze, což případě stejného API (s odlišností verze) znamená porovnání dvou identických URL. Příznak MOV je potom nastaven pokud jsou URL s verzemi rozdílné a URL bez verzí stejné.

Algoritmus podporuje standardní verzovací formát major.minor.micro, který je vyjádřen regulárním výrazem: /[vV][0-9]+(?:[.-][0-9]+){0,2}/.

5.4 Vyhodnocení výsledků

Mezivýsledky porovnání jednotlivých elementů stromu metadat jsou ukládány do hierarchické struktury Diff a vždy po vyhodnocení všech rozdílů potomků dvou uzlů, dojde na základě těchto i k vyhodnocení rozdílů uzlů samotných. Úroveň rozdílu jež určuje finální kompatibilitu webových služeb je dána úrovní kořenového Diff, který drží celou strukturu popisující detailní rozdíly mezi službami.

Příklad tvorby *Diff* při porovnání dvou operací je znázorněn na obrázku 5.4. Nejdříve dojde k vyhodnocení rozdílů listů, tedy atributů *name* a *type* parametrů obou operací, čímž vzniknou *type diff* a *name diff*. Na základě těchto se určí rozdíl mezi parametry samotnými (*parameter diff*) a po porovnání metadat operací (*metadata diff*) je vyhodnocen i výsledný rozdíl obou operací jež je reprezentován objektem *endpoint diff*.



Obrázek 5.4: Tvorba rozdílů mezi dvěma endpointy

Vyhodnocení úrovně rozdílu *Diff* na základě jeho potomků je řízeno prioritou. Každá z úrovní rozdílů *Difference* popsaných v tabulce 5.1 má určitou prioritu, která reprezentuje závažnost rozdílu. Uzel od svých potomků vždy přejímá *Difference* s nejvyšší prioritou, čímž je zaručeno, že se rozdíly narušující kompatibilitu projeví na finálním verdiktu.

Pokud tedy například dojde k rozdílu *UNK* (maximální priorita) při porovnání dvou atributů parametru endpointu, postupným vyhodnocováním se tato *Difference* dostane až ke kořenovému uzlu a výsledná kompatibilita bude mít hodnotu *UNK*. Hodnoty jsou v tabulce 5.1 seřazeny od nejnižší priority po nejvyšší.

5.4.1 Dopad na klienta

Výše popsané úrovně *Difference* mají rozdílný dopad na klienta. Ten se dá rozdělit do skupin bezpečné, potenciálně nebezpečné a nebezpečné, tak jak je tomu v tabulce 5.9. Následující odstavce popisují dopad na klienta pro jednotlivé úrovně a zdůvodňují jejich zařazení do dané skupiny.

Difference	Dopad na klienta
None (NON)	bezpečné
Specialization (SPE)	bezpečné
Insertion (INS)	bezpečné
Deletion (DEL)	potenciálně nebezpečné
Generalization (GEN)	potenciálně nebezpečné
Mutation (MUT)	nebezpečné
Unkown (UNK)	nebezpečné

Tabulka 5.9: Dopad jednotlivých úrovní rozdílu na klienta

Bezpečné rozdíly

Pokud je rozdíl mezi službami v bezpečné skupině, může klient transparentně volat obě služby, aniž by došlo k jakékoliv chybě v rámci kontraktu. Úroveň SPE sice označuje specializaci, nicméně změny SPE a GEN mohou nastat pouze v případě neshody datových typů parametrů, nebo odpovědi operace. V takovém případě je aplikován princip kontravariance [1] podle kterého platí, že F'(a') <: F(a) <=> a <: a'. SPE tedy znamená bezpečnou změnu GEN u parametrů, nebo odpovědi operace.

Změna *INS* nastává v případě, že druhá webová služba obsahuje operace, které nejsou v první definované. Vzhledem k tomu, že je klient nemohl volat a nemůže tak dojít k porušení kontraktu webové služby, je tato změna brána jako bezpečná.

Potenciálně nebezpečné rozdíly

Změny v této skupině mohou mít nebezpečný dopad na klienta ve smyslu volání operace webové služby s neplatným kontraktem, nicméně nejsou tak závažné jako změny nebezpečné. Posouzení reálného rizika změny provádí klient na základě vráceného objektu popisujícího kompatibilitu služeb.

Uroveň *DEL* označuje element definovaný v první službě, ale chybějící v druhé. Může se jednat například o *service*, nebo operaci služby. Úroveň *GEN* je získána, stejně jako *SPE*, na základě principu kontravariance a označuje

změnu v datovém typu (parametru, odpovědi operace, ...), například z long na int.

Nebezpečné rozdíly

Změny v této skupině představují buď kombinace několika méně závažných změn (MUT), nebo neporovnatelnost obou webových služeb (UNK). Stejně jako u předchozí skupiny, i zde může klient použít výsledky porovnání a sám rozhodnout o míře nekompatibility. Úroveň MUT může například nastat i kombinací rozdílů endpointů, které klient nepoužívá a druhá webová služba tak pro něj může být stále kompatibilní.

Úroveň *UNK* označuje buď neporovnatelnost metadat a v takovém případě nelze o kompatibilitě jednoznačně rozhodnout, nebo nerovnost metadat v případě, kde možným výsledkem je pouze 'stejné', nebo 'nestejné'.

6 Implementace rozšíření CRCE

Cílem mé práce bylo vytvořit rozšíření CRCE schopné automatické kontroly kompatibility indexovaných webových služeb. Tato kapitola obsahuje stručný popis implementace rozšíření, jež realizuje algoritmus popsaný v předešlé kapitole. Na konci kapitoly je pak popsáno napojení rozšíření na existující REST API.

6.1 Porovnávač

V kapitole 4 bylo zmíněno, že CRCE má modulární architekturu. Moduly, jež jsou nadstavbou jádra jsou umístěny v modulu crce-modules-reactor. Zde je umístěno i mé rozšíření.

TODO: formulace Z důvodů zmíněných v sekci 5.2 je algoritmus implementován ve dvou verzích. Jedna verze pro služby indexované z implementace, druhá pro služby indexované z popisu. I když je struktura porovnávačů podobná, rozhodl jsem se nedělat žádnou společnou implementaci, protože bych tím do kódu zanesl silnou vazbu, která by v případě změny struktury metadat u jednoho z indexerů přinášela obtíže při následné refaktorizaci. Jediným společným předkem je obecné rozhraní pro porovnávač webových služeb.

Obrázek 6.1: Diagram tříd popisující strukturu porovnávače

6.2 REST API

Oproti modulům pro indexaci komponent, není mé rozšíření napojeno na žádnou z částí životního cyklu komponenty a je tedy nutné jej explicitně volat. To je v současné době provedeno skrze volání REST API.

7 Ověření funkčnosti

- nějaká reálná data - STAG (WSDL) - Fuel Economy - i syntetická data - algoritmus testován pomocí unit testů

7.1 Integrační + akceptační testy

- testování skrze REST API - pomocí Postman (Collection Runner) - několik verzí jednoho API -> testování křížem - todo: příklad - popsat verze API (čím se liší), případně zdůvodnit očekávaný výsledek - tabulka vzájemného porovnání s výsledky

7.1.1 Syntetický server v Jave

- postaveno na Jersey
- REST API
- alespoň obrázek/raml api?
- 2 verze otestované křížem

Popis verzí API (rozdíl je vždy popsaný oproti verzi 1):

- V1: základní verze
- V2: typ parametru změněn z Long na Number

Co se testuje:

• GEN/SPEC a kontravariance u parametru endpointu

7.1.2 Příklad JSON-WSP z wiki

- popsáno JSON-WSP souborem
- https://en.wikipedia.org/wiki/JSON-WSP
- 4 verze otestované křížem

Popis verzí API (rozdíl je vždy popsaný oproti verzi 1):

• V1: základní verze

- V2: typ User je jiný
- V3: přidána metoda deleteUser
- v4: metoda listGroups změněna na getUsersInGroup

Co se testuje:

- ne-indexování custom datových typů (takže v2 = v1)
- mutace endpointu
- INS, DEL

7.1.3 FuelEconomy API

- popsáno WADL souborem
- https://www.fueleconomy.gov/ws/rest/application.wadl
- 3 verze otestované křížem

Popis verzí API (rozdíl je vždy popsaný oproti verzi 1):

- V1: základní verze
- V2: odebrán (poslední) resource /labelvehicle
- V3: odebrán (poslední) resource /labelvehicle, přidán resource /somethingDifferent

Co se testuje:

• INS, DEL a MUT

7.1.4 Stag WS

TODO

8 Závěr

Literatura

- [1] ABADI, M. CARDELLI, L. On Subtyping and Matching. In European Conference on Object-Oriented Programming (ECOOP), Lecture Notes in Computer Science, 952, s. 145–167. ACM Press, January 1995. Dostupné z: https://www.microsoft.com/en-us/research/publication/on-subtyping-and-matching/.
- [2] Berners-Lee, T. Web Services Program Integration across Application and Organization boundaries [online]. aug 2009. Dostupné z: https://www.w3.org/DesignIssues/WebServices.html.
- [3] BRADA, P. JEZEK, K. Repository and Meta-Data Design for Efficient Component Consistency Verification. Science of Computer Programming. 2015, 97, part 3, s. 349–365. ISSN 0167-6423. doi: 10.1016/j.scico.2014.06.013. Dostupné z: http: //www.sciencedirect.com/science/article/pii/S0167642314002925.
- [4] Brada, P. Valenta, L. Practical Verification of Component Substitutability Using Subtype Relation. s. 38 – 45, 10 2006. doi: 10.1109/EUROMICRO.2006.50.
- [5] HESSOVÁ, G. Automatické získání historických údajů z webových zdrojů [online]. Bakalářská práce, Západočeská univerzita v Plzni, Fakulta aplikovaných věd, Plzeň, 2015 [cit. 2020-02-22]. Dostupné z: https://theses.cz/id/pzbgj7/.
- [6] PEJŘIMOVSKÝ, D. Vytváření a ukládání popisu webových služeb v úložišti CRCE [online]. Diplomová práce, Západočeská univerzita v Plzni, Fakulta aplikovaných věd, Plzeň, 2015 [cit. 2020-02-22]. Dostupné z: https://theses.cz/id/bb74eq/.
- [7] W3C. Web Services Architecture [online]. feb 2004. Dostupné z: http://www.w3.org/TR/2004/NOTE-ws-arch-20040211/.
- [8] W3C. Web Services Description Language (WSDL) 1.1 [online]. mar 2001. Dostupné z: https://www.w3.org/TR/2001/NOTE-wsdl-20010315.
- [9] W3C. Web Services Description Language (WSDL) Version 2.0 Part 1: Core Language [online]. jun 2007. Dostupné z: https://www.w3.org/TR/wsdl/.

[10] WOOD, T. How are REST APIs versioned? [online]. sep 2014. Dostupné z: http://www.lexicalscope.com/blog/2012/03/12/how-are-rest-apis-versioned/.

Seznam zkratek

CRCE Component Repository supporting Compatibility Evaluation

API Application Programming Interface

HTTP Hypertext Transfer Protocol

JAR Java Archive

JSON JavaScript Object Notation **JSON** JSON Web-Service Protocol OSGi Open Services Gateway initiative REST Representational State Transfer SOAP Simple Object Access Protocol UML Unified Modeling Language URI Uniform Resource Identifier URL Uniform Resource Locator

WADL Web Application Description Language
WSDL Web Services Description Language

XML Extensible Markup Language

XSD XML Schema Definition

Příloha A - WSDL webové služby pro komix Dilbert

Tady bude WSDL